

**KLASIFIKASI RISIKO PENYAKIT JANTUNG
KARDIOVASKULAR MENGGUNAKAN RANDOM FOREST dan
SVM BERBASIS DATA MEDIS PASIEN**

KESEHATAN & MEDIS



Disusun Oleh Kelompok 1:

Abbie Dzakwan Putra Setyawan - 11241001

Dylan Sukma Yudha - 11241027

Muhammad Nabil Ihyalfikra - 11241058

Tiara Saparang - 11241085

**PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI INFORMASI
INSTITUT TEKNOLOGI KALIMANTAN**

2026

1. PENDAHULUAN

Penyakit jantung merupakan salah satu masalah kesehatan global yang memiliki tingkat kematian tinggi dan menjadi penyebab utama kematian di berbagai negara. Kondisi ini dipengaruhi oleh berbagai faktor risiko seperti hipertensi, diabetes, obesitas, pola hidup tidak sehat, kebiasaan merokok, serta faktor genetik dapat memicu penyakit jantung. Tingginya angka kejadian penyakit jantung menuntut adanya sistem prediksi yang mampu membantu dalam melakukan deteksi dini secara cepat dan akurat. Salah satu cara untuk melakukan pendeteksi dini adalah dengan menggunakan pembelajaran mesin atau machine learning. Machine learning merupakan bagian dari kecerdasan buatan yang memungkinkan komputer untuk belajar dan membuat keputusan tanpa harus diprogram secara eksplisit ini memberi mesin kemampuan untuk berperilaku mengambil keputusan dan menyesuaikan diri dengan perubahan. Machine learning memberikan hasil yang tepat dengan teknik yang cerdas untuk menangani data besar.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk membangun model klasifikasi risiko penyakit jantung kardiovaskular menggunakan dua algoritma model machine learning, yaitu model Random Forest dan model Support Vector Machine (SVM). Kedua algoritma ini dipilih karena memiliki performa yang baik dalam klasifikasi data medis, sehingga diharapkan mampu menghasilkan prediksi yang akurat dalam membedakan pasien yang berisiko dan tidak berisiko penyakit jantung. Algoritma Support Vector Machine (SVM) dikenal memiliki tingkat akurasi yang tinggi dalam proses klasifikasi data. SVM bekerja dengan mencari *hyperplane* optimal yang mampu memisahkan dua kelas data, yaitu pasien normal dan pasien dengan penyakit jantung, dengan margin yang paling lebar sehingga menghasilkan kemampuan generalisasi yang baik terhadap data baru. Selain itu, algoritma Random Forest juga dikenal memiliki performa yang tinggi dalam tugas klasifikasi karena mampu menggabungkan banyak pohon keputusan untuk meningkatkan akurasi dan mengurangi risiko overfitting.

A. Dataset

Untuk membangun model prediksi ini memanfaatkan dataset Heart Failure Prediction yang bersumber dari platform Kaggle. Dataset ini relevan karena di dalamnya terdapat 11 fitur klinis yang mencerminkan kondisi kesehatan pasien dan terdiri dari 918 data pasien.

Tabel 1. Fitur Dataset

Nama Fitur	Keterangan
Age	Usia pasien
Sex	Jenis kelamin pasien
ChestPainType	Tipe nyeri dada pasien
RestingBP	Tekanan darah saat istirahat
Cholesterol	Kadar kolesterol dalam darah
FastingBS	Gula darah puasa (>120mg/dl atau tidak)
RestingEGC	Hasil elektrokardiogram saat istirahat
MaxHR	Detak jantung maksimum yang dicapai
ExerciseAngina	Angina yang dipicu oleh aktivitas fisik
Oldpeak	Depresi segmen ST akibat olahraga
ST_Slope	Kemiringan segmen ST pada puncak olahraga

Tabel 1 merupakan fitur dataset yang terdiri dari 11 fitur data pasien. Dataset ini dipilih karena memiliki jumlah dataset yang cukup besar serta variasi fitur yang relevan untuk membantu model dalam menganalisis penyakit jantung, sehingga mendapatkan pembangunan model klasifikasi yang akurat.

Kaggle :

(<https://www.kaggle.com/code/youssefabdelghfar/heart-failure-prediction-dataset>)

B. Paper Referensi Utama

Paper referensi utama yang digunakan dalam penelitian ini berjudul:

“Prediksi Penyakit Jantung Menggunakan Metode Random Forest dan Principal Component Analysis (PCA)” oleh Alfajr dan Defiyanti (2024).

Gambar 1. Abstrak dari jurnal referensi

Abstrak. Penyakit jantung merupakan masalah kesehatan masyarakat yang signifikan dan menjadi penyebab kematian utama di seluruh dunia. Faktor risiko seperti hipertensi, diabetes, obesitas, gaya hidup tidak aktif, merokok, dan faktor genetik berkontribusi terhadap perkembangan penyakit ini. Penelitian ini bertujuan untuk mengembangkan model prediksi penyakit jantung menggunakan metode Random Forest. Dataset yang digunakan berasal dari UCI Machine Learning Repository dengan sampel 1026 pasien yang memiliki berbagai indikator kesehatan. Proses yang dilakukan meliputi tahapan dalam *knowledge discovery in database (KDD)*, yaitu *data selection*, *preprocessing*, *transformation*, *data mining* dan *evaluation*. Hasil penelitian menunjukkan bahwa model dengan 100 pohon keputusan mencapai akurasi 0.9823. Evaluasi menggunakan *confussion matrix* dan *classification report* menunjukkan metode Random Forest memberikan akurasi 98%, presisi 100%, recall 96%, dan F1-score 98%. Kesimpulannya, metode Random Forest efektif untuk memprediksi penyakit jantung, dengan fitur *thal* yang sangat mempengaruhi akurasi model.

Paper ini membahas mengenai prediksi penyakit jantung menggunakan metode Random Forest dan Principal Component Analysis (PCA). Jurnal tersebut menggunakan dataset yang bersumber dari UCI Machine Learning Repository dan menerapkan tahapan Knowledge Discovery in Database (KDD) yang sistematis, yang mencakup keseluruhan proses dari pembersihan data (*Preprocessing*) hingga penilaian hasil (*evaluation*). Melalui kedua model yang dikombinasikan didapat tingkat akurasi yang cukup tinggi, yaitu sebesar 98,23 % dengan tingkat presisi mencapai 100 %, yang membuktikan pendekatan kombinasi kedua model tersebut cukup efektif dalam melakukan deteksi dini penyakit jantung.

2. PROGRESS PRA-PEMROSESAN DATA dan EDA

Setelah dataset Heart Failure Prediction berhasil dimuat tahapan selanjutnya merupakan pra-pemrosesan dan *Exploratory Data Analysis* (EDA) yang terdiri dari beberapa tahapan. Tahapan ini merupakan bagian dari metodologi *Knowledge Discovery in Database* (KDD) yang bertujuan untuk memastikan data yang dimuat layak untuk digunakan sebelum masuk ke model.

2.1. Pra-Pemrosesan Data

Pra-pemrosesan data merupakan tahapan transformasi terhadap data mentah sebelum digunakan untuk melatih model machine learning. Data mentah pada umumnya tidak selalu siap untuk digunakan, seringkali terdapat nilai yang tidak konsisten, nilai null, data duplikat ataupun format lain yang dapat mengganggu algoritma model saat dilatih. Pada dataset Heart Failure Prediction, meskipun tidak terdapat missing values tetapi terdapat permasalahan lain yang perlu ditangani terlebih dahulu, seperti adanya nilai 0 yang tidak valid secara medis pada kolom cholesterol dan RestingBP. Keadaan beberapa tersebut menyebabkan tidak bisa langsung diproses oleh algoritma SVM dan algoritma RandomForest, oleh karena itu diperlukan tahapan berikut.

A. Penghapusan Data Duplikat

```
df.drop_duplicates(inplace=True)
```

Dataset Heart Failure Prediction merupakan gabungan dari lima dataset independen, sehingga memiliki baris data pasien yang identik. Data duplikat dapat menyebabkan model machine learning “menghafal” pola yang sama secara berulang kali sehingga hasil evaluasi menjadi bias dan mengganggu kemampuan model. Penghapusan data yang duplikat dilakukan sebagai langkah awal untuk memastikan setiap data pasien hanya mewakili satu kali dalam dataset.

B. Penanganan Nilai Tidak Valid

```
for col in ['Cholesterol', 'RestingBP']:
    median = df.loc[df[col] != 0, col].median()
    df[col] = df[col].replace(0, median)
```

Dataset pada kolom Cholesterol dan RestingBP ditemukan memiliki nilai 0 yang tidak mungkin secara medis, karena tidak mungkin manusia dapat hidup tanpa ada kadar kolesterol dan tekanan darah bernilai 0. Nilai tersebut merupakan anomali dalam sebuah dataset sehingga perlu ditangani sebelum masuk ke dalam model. Nilai anomali tersebut diganti dengan nilai median dari data yang valid karena nilai median lebih robust terhadap outlier atau tidak mudah terpengaruh terhadap data ekstrim dibandingkan mean, sehingga tidak menggeser distribusi data secara berlebihan.

C. Penanganan Outlier Dengan Metode Winsorizing

```
num_cols = ['Age', 'RestingBP', 'Cholesterol', 'MaxHR',  
            'Oldpeak']  
for col in num_cols:  
    df[col] = df[col].clip(df[col].quantile(0.01),  
                           df[col].quantile(0.99))  
  
print(f"Shape setelah cleansing: {df.shape}")
```

Winsorizing merupakan metode penanganan outlier yang bekerja dengan cara membatasi nilai ekstrim pada ambang batas persentase tertentu. Dalam metode ini, nilai yang terlalu rendah atau terlalu tinggi akan ditetapkan (misalnya membatasi pada 1% data terendah dan 1% data tertinggi). Jika ada data yang melewati batas tersebut, nilainya akan ditarik atau disamakan dengan batas yang sudah ditentukan.

Nilai ekstrim pada lima kolom numerik yaitu Age, RestingBP, Cholesterol, MaxHR, dan Oldpeak ditangani menggunakan metode ini. Berbeda dengan metode IQR yang menghapus baris secara permanen, Winsorization hanya memangkas nilai ekstrim ke batas persentil tanpa mengurangi jumlah data. Pendekatan ini dipilih karena dataset hanya berjumlah 918 baris sehingga menghapus baris justru dapat merugikan performa model. Selain itu, algoritma SVM dan algoritma Random Forest sangat sensitif terhadap nilai ekstrim karena bekerja berdasarkan jarak antar titik data ke hyperplane, outlier yang tidak ditangani dapat menggeser posisi hyperplane secara drastis sehingga menurunkan akurasi prediksi.

D. Encoding Fitur Kategorikal Dengan One-Hot Encoding

```
df = pd.get_dummies(df,  
    columns=['Sex', 'ChestPainType', 'RestingECG',  
            'ExerciseAngina', 'ST_Slope'],  
    drop_first=True)
```

One-Hot Encoding berfungsi untuk mengubah atribut kategori menjadi bentuk numerik agar bisa diproses oleh algoritma machine learning. Encoding diperlukan karena sebagian besar model algoritma machine learning bekerja secara matematis, sehingga tidak dapat menerima input berupa teks langsung. Terdapat beberapa metode encoding yang umum digunakan seperti, Integer Encoding yang merubah kategori menjadi angka berurutan, dan One-Hot Encoding yang mengubah setiap kategori kolom menjadi kolom biner tersendiri yang bernilai 0 dan 1.

Metode One-Hot Encoding digunakan untuk mengubah lima kolom kategorikal yaitu pada kolom sex, ChestPainType, RestingECG, ExerciseAngina, dan ST_Slope. One-Hot Encoding bekerja dengan cara membuat kolom baru untuk setiap kategori unik yang ada, di mana kolom tersebut akan bernilai 1 jika baris data termasuk ke kategori tersebut, dan akan bernilai 0 jika baris data tidak termasuk ke dalam kategori. Metode ini digunakan karena kelima kolom tersebut bersifat nominal, yang dimana tidak memiliki urutan logis antar kategorinya sehingga tidak tepat jika menggunakan Integer Encoding. Misalnya ChestPainType dikodekan sebagai 1,2,3,4 maka model akan menganggap tipe 4 lebih tinggi dibandingkan yang lainnya. Parameter drop_first diterapkan untuk menghindari dummy variable trap, yaitu kondisi dimana satu kolom diprediksi sempurna dari kolom lainnya sehingga menyebabkan multikolinearitas pada model. Hasil One-Hot Encoding ini berlaku untuk kedua model — baik SVM maupun Random Forest — karena keduanya menggunakan dataset yang sama pada tahap ini.

E. Pembagian Data (Data Split)

```
X = df.drop(columns='HeartDisease')
y = df['HeartDisease']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=43, stratify=y
)
```

Dataset dibagi menjadi 80% data training dan 20% data testing. Parameter `stratify=y` digunakan untuk memastikan proporsi kelas Normal dan Heart Disease tetap seimbang di kedua bagian data. Parameter `random_state=43` memastikan hasil pembagian selalu konsisten setiap kali kode dijalankan. Penting untuk dicatat bahwa pembagian data ini digunakan bersama oleh kedua model SVM dan Random Forest menggunakan `X_train` dan `X_test` yang sama sehingga perbandingan antar model menjadi adil dan valid.

F. Normalisasi Fitur dengan StandardScaler

```
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)
```

Seluruh fitur numerik dinormalisasi menggunakan `StandardScaler` yang mengubah setiap fitur sehingga memiliki mean = 0 dan standar deviasi = 1. `StandardScaler` hanya digunakan untuk model SVM, karena model tersebut mencari hyperplane optimal berdasarkan jarak antar titik sehingga sangat sensitif terhadap perbedaan skala fitur. Sementara itu, Random Forest tidak menggunakan scaling karena algoritma ini bekerja berdasarkan pemilihan threshold pada setiap fitur secara independen sehingga tidak terpengaruh oleh perbedaan skala.

2.2. Exploratory Data Analysis (EDA)

EDA adalah proses analisis yang dilakukan untuk memahami karakteristik data serta mengevaluasi hasil prediksi model secara visual. Pada penelitian ini EDA difokuskan pada tiga visualisasi utama yang dipilih yaitu memprediksi penyakit jantung dan membandingkan performa dua model machine learning secara objektif.

A. Confusion Matrix


Confusion Matrix adalah tabel evaluasi yang menggambarkan hasil prediksi model secara rinci dengan membandingkan nilai prediksi terhadap nilai aktual. Setiap sel dalam matriks merepresentasikan salah satu dari empat kondisi berikut:

Tabel 2. Confusion Matrix

Prediksi	Keterangan
True Positive (TP)	Pasien yang benar-benar mengidap penyakit jantung dan berhasil diprediksi sakit oleh model
True Negative (TN)	Pasien yang benar-benar sehat dan berhasil diprediksi sehat oleh model
False Positive (FP)	Pasien yang sebenarnya sehat namun diprediksi sakit oleh model
False Negative (FN)	Pasien yang sebenarnya sakit namun diprediksi normal oleh model

Tabel 2 merupakan prediksi yang akan dilakukan oleh model. Dalam konteks prediksi penyakit jantung, kondisi False Negative menjadi perhatian paling utama karena berarti pasien yang sesungguhnya mengidap penyakit jantung tidak terdeteksi oleh model.

Gambar 1. Confusion Matrix



Melalui gambar 1 kita dapat melihat disana terdapat dua confusion matrix, confusion matrix untuk model SVM diwakilkan berwarna biru, dan confusion matrix untuk model Random Forest diwakilkan berwarna hijau.

Pada model SVM, kita dapat melihat bahwa tingkat akurasi dalam menilai pasien normal yang diprediksi normal sebanyak 66 pasien (*True Negative*), pasien normal yang diprediksi sakit sebanyak 16 pasien (*False Positive*), pasien sakit yang diprediksi sakit sebanyak 93 pasien (*True Positive*), dan pasien sakit yang diprediksi normal sebanyak 9 pasien (*False Negative*).

Pada model Random Forest kita dapat melihat tingkat akurasinya model tersebut dengan prediksinya terhadap pasien. Pasien normal yang diprediksi normal terdapat 68 pasien (*True Negative*), pasien normal yang diprediksi sakit terdapat 14 pasien (*False Positive*), pasien sakit yang diprediksi sakit sebanyak 92 pasien (*True Positive*), dan pasien sakit yang diprediksi sakit sebanyak 10 pasien (*False Negative*).


Berdasarkan hasil dari kedua confusion matrix tersebut dapat disimpulkan bahwa kedua model tersebut dapat memprediksi pasien dengan cukup baik, walaupun keduanya masing-masing memiliki pendekatan yang berbeda. Namun, model SVM dapat memprediksi sedikit lebih unggul ketimbang model Random Forest, walaupun perbedaan dari tingkat akurasi kedua model tersebut sangat kecil.

B. ROC Curve Gabungan

ROC Curve (*Receiver Operating Characteristic Curve*) adalah grafik yang menggambarkan kemampuan model dalam membedakan dua kelas yaitu, Normal dan Heart Disease di berbagai nilai threshold keputusan. Sumbu Y merepresentasikan True Positive Rate (*Recall*) yaitu seberapa banyak pasien sakit yang berhasil terdeteksi, sedangkan sumbu X merepresentasikan False Positive Rate yaitu seberapa banyak pasien sehat yang salah diprediksi sebagai sakit. Garis diagonal putus-putus pada grafik merepresentasikan model acak yang tidak memiliki kemampuan prediksi sama sekali, semakin jauh kurva model dari garis diagonal menuju sudut kiri atas, semakin baik kemampuan model tersebut.

Nilai AUC (*Area Under the Curve*) adalah angka yang merangkum keseluruhan kurva ROC menjadi satu nilai tunggal antara 0 hingga 1. Semakin tinggi nilai AUC, semakin baik kemampuan model dalam membedakan pasien yang sakit dan pasien yang sehat. Pada penelitian ini kedua model SVM dan Random Forest, digambarkan dalam satu grafik yang sama sehingga perbandingan dapat dilakukan secara langsung hanya dengan melihat posisi kurva dan nilai AUC masing-masing. Model yang kurvanya lebih menggembung ke arah sudut kiri atas grafik dan memiliki nilai AUC lebih tinggi dapat disimpulkan sebagai model yang lebih unggul dalam melakukan klasifikasi penyakit jantung.

Gambar 2. ROC Curve dan AUC



Pada gambar 2 dapat dilihat perbandingan kurva ROC antara model SVM dan model Random Forest. Kurva ROC merupakan grafik yang menggambarkan kemampuan model dalam membedakan dua kelas, yaitu pasien normal dan pasien dengan penyakit jantung. Sumbu x menunjukkan *False Positive* dan sumbu y yang menunjukkan *True Positive*. Model SVM diwakilkan oleh warna biru dan model Random Forest diwakilkan oleh warna hijau.

Pada model SVM, diperoleh nilai AUC sebesar 0.928, yang berarti model ini memiliki kemampuan yang baik dalam membedakan pasien normal dan pasien dengan penyakit jantung di berbagai nilai *threshold*. Nilai *threshold* merupakan nilai batasan keputusan yang digunakan untuk memprediksi apakah pasien termasuk normal atau memiliki penyakit jantung. Pada model Random Forest diperoleh nilai AUC sebesar 0.935, yang juga menunjukkan kemampuan yang baik dalam membedakan kondisi pasien walaupun sedikit lebih rendah dibandingkan dengan model SVM.

Berdasarkan hasil kurva ROC tersebut maka dapat disimpulkan bahwa kedua model tersebut memiliki kemampuan yang baik dalam memprediksi pasien, ditandai dengan hasil AUC keduanya diatas 0.9. Pada kurva ROC ini memiliki hasil yang berbanding terbalik dengan confusion matrix. Ini disebabkan ROC-AUC mengukur kemampuan model pada keseluruhan di semua nilai *threshold*, sedangkan *confusion matrix* hanya mencerminkan performa model pada satu threshold tertentu. Melalui kurva ROC-AUC tersebut model Random Forest memiliki nilai sedikit lebih unggul dibandingkan dengan model SVM.

C. Bar Chart Perbandingan Metrik

Bar Chart perbandingan metrik menampilkan lima matrik evaluasi utama, Accuracy, Precision, Recall, F1-Score, dan ROC-AUC dari kedua model secara berdampingan dalam satu grafik. Visualisasi ini digunakan agar lebih mudah untuk melihat kekurangan dan kelebihan dari kedua model yang digunakan yaitu model SVM dan Random Forest. Setiap batang dilengkapi dengan label nilai numeriknya sehingga perbedaan performa antar model dapat dibaca secara langsung tanpa perlu merujuk ke tabel terpisah. Melalui visual ini dapat membantu menarik kesimpulan manakah model yang lebih unggul dalam memprediksi penyakit jantung.

Gambar 3. Rumus Akurasi

$$ACCURACY = \frac{TP + TN}{TP + TN + FP + FN}$$

Gambar 3 merupakan rumus yang digunakan dalam menentukan nilai akurasi dari kedua model. Rumus ini berfungsi untuk mengukur seberapa banyak prediksi yang benar secara keseluruhan.

Gambar 4. Rumus Precision

$$PRECISION = \frac{TP}{TP + FP}$$

Gambar 4 merupakan rumus precision yang digunakan dalam kedua model. Rumus ini berfungsi untuk mengukur seberapa ketepatan fungsi prediksi.

Gambar 5. Rumus Recall

$$RECALL = \frac{TP}{TP + FN}$$


Gambar 5 merupakan rumus recall yang digunakan dalam kedua model. Rumus ini berfungsi untuk mengukur kemampuan model dalam menemukan semua kasus positif yang sesungguhnya.

Gambar 6. F-1 Score

$$F - 1Score = 2x \frac{Precision \times Recall}{Precision + Recall}$$

Gambar 6 merupakan rumus F-1 Score yang digunakan dalam kedua model. F1-Score tinggi berarti model seimbang dalam hal ketepatan dan kelengkapan deteksi.

Gambar 7. Bar Chart Metrik



Pada gambar 7 berikut dapat dilihat mengenai perbandingan dari kedua model yang digunakan, warna biru mewakili model SVM dan warna hijau mewakili model Random Forest. Pada pengukuran tingkat akurasi, model SVM memiliki tingkat akurasi sebesar 0.864 dan model Random Forest memiliki tingkat akurasi sebesar 0.870. Pengukuran tingkat presisi, model SVM memiliki tingkat presisi 0.853 dan model Random Forest memiliki tingkat presisi sebesar 0.868. Pada recall model SVM memiliki tingkat recall sebesar 0.912 dan model Random Forest memiliki recall sebesar 0.902. F-1 Score model SVM memiliki nilai sebesar 0.882, dan model Random Forest 0.885. Dan terakhir pada pengukuran ROC-AUC model SVM mendapatkan nilai sebesar 0.928 dan model Random Forest mendapatkan nilai 0.935.

Dapat disimpulkan bahwasanya dari kedua model tersebut walaupun memiliki pendekatan yang berbeda, tetapi perbedaan pengukurannya tidak jauh berbeda dan hanya memiliki selisih yang kecil. Model Random Forest memiliki nilai yang unggul pada tingkat akurasi, presisi, F-1 Score dan ROC-AUC, jika dibandingkan model SVM yang hanya memiliki keunggulan pada recall.

3. Implementasi dan Eksperimen Model

Penelitian ini berfokus pada implementasi dua algoritma *machine learning* utama, yaitu Support Vector Machine (SVM) dan Random Forest, untuk memprediksi penyakit jantung menggunakan dataset *Heart Failure Prediction*. Proses dimulai dengan membangun model *baseline* sebagai titik acuan awal, kemudian dilanjutkan dengan integrasi teknik dari paper referensi, proses optimasi hyperparameter, hingga perbandingan performa antar model secara menyeluruh. Tujuan utama dari bagian ini adalah untuk menunjukkan seberapa baik performa awal kedua model sebelum dilakukan optimasi, serta menjadi dasar perbandingan pada tahap pengembangan selanjutnya.

3.1. Eksperimen Baseline

Sebelum dilakukan optimasi, model SVM dan model Random Forest dijalankan terlebih dahulu menggunakan parameter default bawaan sklearn tanpa proses tuning apapun. Tujuannya adalah untuk mendapatkan gambaran awal performa model sebagai titik pembanding sebelum proses optimasi dilakukan. Tiga parameter utama yang digunakan secara default adalah sebagai berikut:

Baseline model SVM :

```
svm_base = SVC(kernel='rbf', C=1.0,  
gamma='scale',probability=True, random_state=42)  
svm_base.fit(X_train_sc, y_train)
```

Tabel 3. Parameter model SVM

Parameter	Nilai Default	Keterangan
Kernel	rbf	Fungsi pemisah yang digunakan untuk membagi dua kelas data
C	1.0	Mengontrol seberapa ketat model menghindari kesalahan klasifikasi
Gamma	scale	Mengontrol seberapa jauh pengaruh satu titik data terhadap hyperplane

Baseline model Random Forest

```
rf_base = RandomForestClassifier(n_estimators=100,  
random_state=42)  
rf_base.fit(X_train, y_train)
```

Tabel 4. Parameter model Random Forest

Parameter	Nilai Default	Keterangan
n_estimator	100	Jumlah pohon keputusan yang dibangun
Max_depth	1.0	Kedalaman pohon tidak dibatasi
max_features	sqrt	Jumlah fitur yang dipertimbangkan saat mencari split terbaik

Nilai n_estimator = 100 pada model tersebut, mengacu pada refrensi yang juga menggunakan 100 pohon keputusan sebagai konfigurasi dan pada paper tersebut sudah dibuktikan bahwa hasilnya stabil. Model SVM menggunakan data yang sudah di scalling sedangkan Model Random Forest menggunakan data asli, karena model tersebut tidak sensitif terhadap perbedaan skala antar fitur

3.2. Integrasi Metode Paper Referensi

Paper yang digunakan sebagai referensi adalah sebagai berikut :

Alfajr, Nur Halizah, and Sofi Defiyanti. "Prediksi Penyakit Jantung Menggunakan Metode Random Forest dan Penerapan Principal Component Analysis (PCA)." *JITET (Jurnal Informatika dan Teknik Elektro Terapan)*, vol. 12, no. 3S1, 2024.

Terdapat dua teknik dari paper tersebut yang diterapkan pada penelitian ini, teknik pertama yang diterapkan merupakan One-Hot Encoding untuk transformasi data kategorikal. Paper referensi pada bagian *transformation* secara eksplisit menyebutkan penggunaan One-Hot Encoding melalui fungsi *pd.get_dummies* untuk mengubah kolom bertipe teks menjadi angka sebelum data dimasukkan ke dalam model.

Metode One-Hot Encoding

```
df = pd.get_dummies(df,  
    columns=['Sex', 'ChestPainType', 'RestingECG',  
            'ExerciseAngina', 'ST_Slope'],  
    drop_first=True)
```

Seperti yang dijelaskan dalam paper, kolom-kolom kategorikal bersifat nominal sehingga tidak memiliki urutan logis antar kategorinya. One-Hot Encoding memastikan model tidak salah menginterpretasikan hubungan antar kategori sebagai hubungan matematis yang berurutan.

Teknik Kedua yang digunakan merupakan evaluasi dengan menggunakan Confusion Matrix dan Classification Report. Paper referensi pada bagian Evaluation menggunakan Confusion Matrix dan Classification Report sebagai alat evaluasi utama menggunakan empat metrik yaitu Accuracy, Precision, Recall, dan F1-Score. Pendekatan evaluasi yang sama diterapkan pada penelitian ini melalui fungsi `evaluate_baseline()` yang dipanggil untuk kedua model:

Fungsi `evaluate_baseline()` :

```
def evaluate_baseline(model, X_te, y_te, label, params):  
    y_pred = model.predict(X_te)  
    y_prob = model.predict_proba(X_te)[:, 1]  
  
    accuracy = accuracy_score(y_te, y_pred)  
    precision = precision_score(y_te, y_pred)  
    recall = recall_score(y_te, y_pred)  
    f1 = f1_score(y_te, y_pred)  
    auc = roc_auc_score(y_te, y_prob)  
    target_names=['Normal', 'Heart Disease']})")
```

Selain itu, paper referensi juga menerapkan algoritma Random Forest sebagai model utamanya hal inilah yang menjadi landasan penambahan Random Forest pada penelitian ini sebagai model pembanding terhadap SVM.

3.3. Perbedaan dengan Paper Referensi

Paper referensi menggunakan dataset dari UCI Machine Learning Repository dengan 1026 pasien dan 14 fitur serta menerapkan PCA untuk menghapus fitur *fbs* yang dianggap paling tidak berpengaruh. Sementara penelitian ini menggunakan dataset Heart Failure Prediction dari Kaggle dengan 918 pasien dan 11 fitur, serta tidak menerapkan PCA melainkan menggunakan Winsorizing untuk penanganan outlier, pendekatan berbeda namun bertujuan sama yaitu memaksimalkan kualitas data sebelum masuk ke model.

3.4. Tabel Komparasi Performa Baseline

Berikut perbandingan performa kedua model pada kondisi baseline yaitu sebelum dilakukan proses optimasi apapun berdasarkan hasil evaluasi pada data testing:

Tabel 5. Perbandingan Model SVM dan Model Random Forest

Algoritma	Akurasi	Presisi	Recall	F-1 Score	ROC-AUC
Baseline SVM	0.8641	0.8532	0.9118	0.8815	0.9281
Baseline Random Forest	0.8696	0.8679	0.9020	0.8846	0.9353

Berdasarkan hasil eksperimen baseline yang telah dilakukan, model SVM dan model Random Forest sudah menunjukkan performa yang cukup baik meskipun hanya menggunakan parameter default tanpa optimasi apapun. Perbandingan nilai Recall menjadi fokus utama dalam konteks prediksi penyakit jantung karena Recall yang tinggi berarti semakin sedikit pasien sakit yang tidak terdeteksi oleh model. Hasil baseline ini selanjutnya akan menjadi titik acuan untuk mengukur peningkatan performa setelah dilakukan proses optimasi hyperparameter pada tahap berikutnya.

4. Kendala Teknis dan Analisis Error

Dalam mengerjakan penelitian ini, terdapat beberapa kendala teknis yang terjadi

- A. Kesalahan load data heart.csv, ini terjadi pada kode, path yang digunakan merupakan path yang khusus untuk diakses pada kaggle dan bukan pada lokal. Ini menyebabkan data tersebut menjadi tidak bisa terbaca dan error.
- B. Kesalahan urutan pipeline, pada kode awal fungsi evaluasi dibuat lebih awal ketimbang baseline model, yang dimana ini tidak logis. Seharusnya baseline model tersebut dijalankan baru bisa masuk ke dalam fungsi evaluasi model
- C. Kode yang terlalu panjang, pada kode awal dibuat terlalu panjang dan menyulitkan dalam memperbaiki kode sehingga kode dibentuk kembali dengan lebih ringkas

5. Rencana Tindak Lanjut

Berdasarkan progres yang telah kami capai hingga tahap eksperimen model dan evaluasi, kami menyusun beberapa rencana tindak lanjut yang akan dilakukan secara bertahap hingga Final Demo (UAS). Rencana ini kami fokuskan pada penyempurnaan model yang sudah dibangun serta persiapan implementasi agar dapat didemonstrasikan dengan baik.

1. Melakukan finalisasi pipeline Machine Learning secara terintegrasi (Minggu 10)

Seluruh proses mulai dari preprocessing, encoding, pembagian data, normalisasi (khusus SVM), hingga training model akan kami susun menjadi satu pipeline yang utuh. Dengan begitu, alur pengerjaan menjadi lebih rapi dan bisa dijalankan secara konsisten tanpa harus menjalankan tiap tahap secara manual.

2. Menyelesaikan proses hyperparameter tuning dan menentukan model terbaik (minggu 11)

Proses tuning menggunakan RandomizedSearchCV akan kami lanjutkan untuk kedua model. Setelah itu, kami akan membandingkan performanya kembali. Dalam penentuan model terbaik, kami tidak hanya melihat akurasi, tetapi juga mempertimbangkan ROC-AUC dan recall, karena pada kasus ini kemampuan mendeteksi pasien berisiko menjadi hal yang lebih penting.

3. Melakukan analisis error terhadap hasil prediksi model (minggu 12)

Kami akan melihat lebih lanjut kesalahan prediksi, terutama pada False Negative dan False Positive. Dari sini kami ingin mengetahui di bagian mana model masih lemah, sehingga bisa dipertimbangkan apakah perlu perbaikan pada preprocessing atau fitur yang digunakan.

4. Menyimpan model terbaik untuk keperluan implementasi (minggu 13)

Model terbaik nantinya akan disimpan menggunakan Pickle atau Joblib agar dapat digunakan kembali tanpa perlu training ulang. Ini juga menjadi langkah awal untuk integrasi ke dalam sistem demo.

5. Mengembangkan antarmuka sederhana menggunakan Streamlit (Minggu 13 dan 14)

Kami akan membuat tampilan sederhana agar pengguna bisa mencoba langsung model dengan memasukkan data pasien dan melihat hasil prediksi. Dengan adanya

UI ini, model yang kami buat tidak hanya sebatas eksperimen, tetapi juga bisa ditunjukkan penggunaannya.

6. Melakukan pengujian sistem secara menyeluruh (minggu 14 dan 15)

Setelah model dan UI terintegrasi, kami akan melakukan pengujian dari awal sampai akhir untuk memastikan sistem berjalan dengan baik dan tidak terjadi error saat digunakan.

7. Merapikan repositori GitHub dan dokumentasi (minggu 15)

Struktur kode akan kami rapikan agar lebih terorganisir, sekaligus menambahkan dokumentasi yang jelas supaya mudah dipahami.

8. Menyempurnakan laporan akhir (minggu 15)

Laporan akan dilengkapi terutama pada bagian hasil eksperimen lanjutan, analisis error, serta kesimpulan. Selain itu, kami juga akan melakukan pengecekan ulang terhadap format dan penulisan agar sesuai dengan ketentuan.

6. Lampiran

Github : <https://github.com/Bieraaa/Machine-Learning-SVM.git>

JupyterNotebook :  **Tubes Machine Learning_Kelompok 1**